📋 Worksheet 2 – Cost Anatomy Lab

Nhóm: EcoSense Team **Thời gian:** 09:35 – 10:15

---

1. Ước lượng traffic

Chỉ số	MVP	Ghi chú
User/ngày	~500	Người dùng cá nhân, đô thị
Request/ngày	~2,500	Trung bình 5 query/user/ngày
Peak traffic	7:00–8:30 sáng	Trước giờ đi làm/học – hỏi thời tiết, AQI

---

2. Ước lượng token (LLM API)

Thành phần	Token/request	Ghi chú
System prompt	~500	Hướng dẫn agent, context môi trường
User message	~50	Câu hỏi ngắn thường ngày
Dữ liệu API inject vào	~300	JSON thời tiết + AQI từ OpenWeatherMap
Total input	**~850**	
Output (response)	~200	Trả lời + gợi ý hành động
Total/request	**~1,050**	
Total/ngày	**~2,625,000**	2,500 req × 1,050

---

3. Các lớp cost

Lớp	Chi phí ước tính/tháng	Ghi chú
Token (LLM API)	~$420	Input $6.4/ngày + Output $7.5/ngày

Lớp	Chi phí ước tính/tháng	Ghi chú
Compute (Cloud Run)	~$30	Auto-scaling, stateless
External API	~$0–20	OpenWeatherMap free 1,000 calls/ngày; AQI API tương tự
Storage	~$5	Chỉ cache API response tạm thời
Logging	~$5	System log tối thiểu, không lưu data người dùng
Human review	$0	Không áp dụng ở MVP
Maintenance	$0	Dev time, không tính tiền mặt ở hackathon
Tổng MVP	**~$460/tháng**	

---

4. Phân tích khi scale 5x và 10x

Lớp	5x (2,500 users)	10x (5,000 users)	Tăng mạnh?
Token (LLM)	~$2,100	~$4,200	🔴 Tăng tuyến tính, mạnh nhất
External API	~$100	~$250	🟡 Vượt free tier → tính tiền
Compute	~$80	~$150	🟢 Tăng nhẹ nhờ auto-scaling
Storage/Logging	~$10	~$15	🟢 Gần như không đổi

> **Token cost là thứ tăng mạnh và nhanh nhất** khi scale, vì mỗi request đều gọi LLM với context dài (system prompt + API data inject).

---

5. Câu hỏi nhóm phải trả lời

Cost driver lớn nhất?

> LLM token cost – chiếm ~90% tổng chi phí, đặc biệt do context dài vì phải inject dữ liệu thời tiết/AQI vào mỗi request.

Hidden cost dễ bị quên nhất?

> Chi phí **External API khi vượt free tier** – OpenWeatherMap free chỉ 1,000 calls/ngày, EcoSense với 2,500 requests/ngày sẽ vượt ngay từ MVP. Dễ bị bỏ qua vì lúc test thấy miễn phí.

Chỗ nào đang ước lượng quá lạc quan?

> **Peak traffic** – giả định chỉ có buổi sáng, nhưng thực tế có thể có nhiều peak trong ngày (trưa, chiều trước mưa). Nếu peak cao hơn dự tính, compute và token cost sẽ tăng đột biến mà auto-scaling không kịp phản ứng tối ưu.

Đầu ra: ✅ Worksheet 2 hoàn thành