📋 Worksheet 4 – Scaling & Reliability Tabletop

Nhóm: EcoSense Team **Thời gian:** 10:50 – 11:25

1–3. Phân tích 3 tình huống

🔴 Tình huống 1: Traffic tăng đột biến

(Ví dụ: bão đổ bộ, ô nhiễm không khí cực đoan → cả thành phố hỏi cùng lúc)

Tác động tới user	Hệ thống phản hồi chậm hoặc timeout, đúng lúc người dùng cần thông tin nhất
Phản ứng ngắn hạn	Auto-scaling Cloud Run tăng instance; bật Semantic Caching để giảm tải LLM với các câu hỏi lặp
Giải pháp dài hạn	Thiết kế request queue – ưu tiên xử lý cảnh báo khẩn cấp (AQI nguy hiểm) trước; các câu hỏi thông thường vào hàng chờ async

---

🟡 Tình huống 2: Provider Timeout

(LLM API hoặc OpenWeatherMap/AQI API không phản hồi)

Tác động tới user	Không nhận được câu trả lời hoặc nhận thông báo lỗi chung chung, mất tin tưởng
Phản ứng ngắn hạn	Circuit breaker – nếu LLM timeout sau 3s, chuyển sang **rule-based fallback**: trả dữ liệu thời tiết thô từ cache gần nhất kèm disclaimer
Giải pháp dài hạn	Dual provider – backup sang LLM API khác (ví dụ: Gemini nếu Claude timeout); với external API thì cache dữ liệu 30 phút để dùng khi provider lỗi

---

🟠 Tình huống 3: Response chậm

(Latency cao do context quá dài hoặc LLM quá tải)

Tác động tới user	Trải nghiệm chat bị gián đoạn, cảm giác sản phẩm kém chất lượng
Phản ứng ngắn hạn	Áp dụng **Prompt Compression** ngay để giảm token; hiển thị streaming response thay vì chờ full response
Giải pháp dài hạn	Selective Inference – câu hỏi đơn giản không gọi LLM; đặt timeout cứng 5s và trả fallback nếu vượt

---

4. Metrics cần monitor

Metric	Lý do
LLM API latency (P95)	Phát hiện response chậm trước khi user phàn nàn
External API error rate	Theo dõi OpenWeatherMap/AQI có timeout không
Token/request trung bình	Kiểm soát cost, phát hiện context bị phình
Request queue length	Cảnh báo sớm khi traffic tăng đột biến
Cache hit rate	Đánh giá hiệu quả Semantic Caching
Fallback trigger count	Đo mức độ hệ thống phải dùng fallback

---

5. Fallback Proposal

```
Nếu LLM API timeout (>3s):
  → Trả dữ liệu thời tiết/AQI thô từ cache gần nhất
  → Kèm message: "Hệ thống đang bận, đây là dữ liệu cập nhật gần nhất lúc
[timestamp]"

Nếu External API (thời tiết/AQI) lỗi:
  → Thông báo rõ: "Không lấy được dữ liệu mới, vui lòng thử lại sau"
  → Không hallucinate dữ liệu thời tiết

Nếu cả hai đều lỗi:
  → Chuyển sang rule-based: trả thông tin tĩnh theo mùa/khu vực
  → Log incident để review sau
```

💡 Trả lời gợi ý

Câu hỏi	Trả lời
Request nào cần real-time, request nào có thể async?	**Real-time:** cảnh báo AQI nguy hiểm, hỏi thời tiết trước khi ra ngoài. **Async:** báo cáo xu hướng, lịch sử AQI tuần qua
Có cần queue, circuit breaker hay retry policy không?	**Có cả 3** – queue cho peak traffic, circuit breaker cho provider timeout, retry policy (tối đa 2 lần) cho lỗi tạm thời
Fallback nên là model khác, rule-based hay human escalation?	**Rule-based trước** (nhanh, rẻ) → **model khác** nếu rule-based không đủ → **human escalation không cần** vì đây là app B2C

Đầu ra: ✅ Worksheet 4 hoàn thành